


PREDIKSI KEBERHASILAN UMKM BERBASIS MACHINE LEARNING



Tema: Data-Driven Solution untuk Permasalahan Nyata

Nama Tim: Magic Cloud

Anggota: Evan William, Daniel, Bambang Herlambang

UNIVERSITAS WIDYA MANDALA SURABAYA

Informatics Festival 2026
Universitas PGRI Semarang

Abstrak

UMKM memiliki peran strategis dalam perekonomian, tetapi tingkat keberhasilannya dipengaruhi oleh banyak faktor operasional seperti kecukupan modal, pencatatan keuangan, penggunaan internet, rencana bisnis, pengalaman industri, dan konsultasi profesional. Makalah ini membangun pendekatan machine learning untuk memprediksi keberhasilan UMKM menggunakan dataset panitia yang terdiri atas 250 observasi dan 13 kolom. Target Success memiliki distribusi tidak seimbang, yaitu 188 UMKM tidak berhasil dan 62 UMKM berhasil. Analisis dilakukan melalui audit data, eksplorasi fitur, validasi model, interpretasi fitur, dan penyusunan rekomendasi.

1. Pendahuluan

1.1 Latar Belakang

UMKM merupakan motor ekonomi lokal yang berperan dalam penciptaan lapangan kerja, pemerataan pendapatan, dan penguatan ekonomi masyarakat. Namun, tidak semua UMKM mampu bertahan dan berkembang secara berkelanjutan. Kegagalan dapat dipengaruhi oleh keterbatasan modal, rendahnya literasi pencatatan keuangan, kurangnya rencana bisnis, rendahnya pemanfaatan internet, serta minimnya akses terhadap nasihat profesional.

Pendekatan data science dapat membantu mengidentifikasi faktor yang berhubungan dengan keberhasilan UMKM. Dengan model prediktif, pendamping usaha, pemerintah, komunitas bisnis, dan pelaku UMKM dapat memprioritaskan intervensi yang paling berdampak. Analisis ini selaras dengan tema kompetisi, yaitu Data-Driven Solution untuk Permasalahan Nyata.

1.2 Rumusan Masalah

- Bagaimana karakteristik dataset UMKM yang diberikan panitia?
- Faktor apa saja yang paling berkaitan dengan keberhasilan UMKM?
- Bagaimana membangun model machine learning yang valid untuk memprediksi keberhasilan UMKM?
- Rekomendasi praktis apa yang dapat diberikan berdasarkan hasil analisis?

1.3 Tujuan

Tujuan proyek ini adalah membangun pipeline analisis dan prediksi keberhasilan UMKM, mengevaluasi model secara adil pada data yang tidak seimbang, menginterpretasikan fitur penting, dan menyusun rekomendasi nyata untuk meningkatkan peluang keberhasilan UMKM.

2. Landasan Teori

2.1 Data Science dan Machine Learning

Data science menggabungkan pengolahan data, statistik, machine learning, dan pemahaman domain untuk menghasilkan informasi yang dapat digunakan dalam pengambilan keputusan. Dalam kasus ini, machine learning digunakan untuk mempelajari pola historis antara profil UMKM dan label keberhasilan.

2.2 Klasifikasi Biner

Prediksi keberhasilan UMKM merupakan masalah klasifikasi biner karena target hanya memiliki dua kelas: berhasil dan tidak berhasil. Model yang digunakan perlu mampu membedakan kedua kelas sekaligus menjaga performa pada kelas minoritas.

2.3 Evaluasi pada Data Tidak Seimbang

Dataset memiliki distribusi target tidak seimbang: 75,2 persen kelas 0 dan 24,8 persen kelas 1. Accuracy saja tidak cukup karena model yang selalu menebak kelas mayoritas dapat terlihat cukup baik. Oleh sebab itu, evaluasi juga menggunakan balanced accuracy, precision, recall, F1-score, dan ROC-AUC.

2.4 Interpretabilitas Model

Interpretabilitas penting agar hasil prediksi dapat diterjemahkan menjadi kebijakan atau tindakan. Permutation importance digunakan untuk melihat penurunan performa ketika suatu fitur diacak. Pada model linear, koefisien terstandarisasi juga membantu membaca arah pengaruh fitur.

3. Proses Analisis

3.1 Data dan Variabel

Dataset `umkm_success.csv` berisi 250 baris dan 13 kolom. Variabel target adalah Success. Fitur yang dianalisis meliputi usia pemilik, pendidikan, kecukupan modal awal, pencatatan keuangan, penggunaan internet, rencana bisnis, usaha pemasaran, kemitraan, pengalaman bisnis orang tua, pengalaman industri, gender pemilik, dan frekuensi konsultasi profesional.

3.2 Audit Kualitas Data

Audit awal menunjukkan tidak terdapat missing value pada seluruh kolom. Semua variabel terbaca sebagai numerik. Target terdiri atas 188 data tidak berhasil dan 62 data berhasil. Ketidakseimbangan ini menjadi pertimbangan utama dalam pemilihan metrik dan strategi validasi.

3.3 EDA, Modeling, dan Validasi

EDA dilakukan dengan melihat distribusi target, ringkasan statistik, success rate pada fitur biner, boxplot fitur numerik terhadap target, dan korelasi antarvariabel. Notebook membandingkan baseline mayoritas dengan Logistic Regression, Random Forest, Extra Trees, Gradient Boosting, dan AdaBoost. Data dipisahkan secara stratified, cross-validation menggunakan `RepeatedStratifiedKFold`, dan model terbaik dipilih berdasarkan ROC-AUC serta F1-score.

4. Hasil Analisis

4.1 Ringkasan Dataset

Indikator	Nilai
Jumlah baris	250
Jumlah kolom	13
Jumlah fitur prediktor	12
Missing value	0

Indikator	Nilai
Kelas tidak berhasil	188 (75,2%)
Kelas berhasil	62 (24,8%)

4.2 Pola Success Rate

Fitur	Kondisi 0	Kondisi 1	Interpretasi
Business_Plan	8,4%	39,7%	Rencana bisnis sangat terkait dengan peluang berhasil.
Initial_Capital	9,9%	38,8%	Modal awal memadai membantu stabilitas operasional.
Financial_Record_Keeping	10,9%	39,3%	Pencatatan baik membantu kontrol arus kas dan evaluasi.
Internet_Usage	12,1%	40,9%	Internet mendukung pemasaran dan pasar digital.
Owner_Gender	24,8%	24,8%	Gender bukan pembeda utama pada dataset ini.

4.3 Hasil Model

Pada validasi lokal berbasis Logistic Regression terstandarisasi dengan class balancing, hasil indikatif yang diperoleh adalah accuracy sekitar 0,939, balanced accuracy sekitar 0,952, F1-score sekitar 0,890, dan ROC-AUC sekitar 0,989 pada repeated stratified cross-validation. Pada holdout stratified, threshold yang disesuaikan memberi accuracy sekitar 0,941, F1-score sekitar 0,889, dan ROC-AUC sekitar 0,994. Nilai final pada Kaggle dapat sedikit berbeda karena notebook melakukan pemilihan model dan tuning ulang secara langsung.

4.4 Interpretasi Fitur

Fitur dengan kontribusi paling kuat secara konsisten adalah Internet_Usage, Business_Plan, Financial_Record_Keeping, Initial_Capital, Professional_Advice, dan Industry_Experience. Temuan ini penting karena sebagian besar faktor tersebut dapat ditingkatkan melalui pelatihan, pendampingan, akses modal, dan transformasi digital.

4.5 Diskusi

Hasil analisis menunjukkan bahwa keberhasilan UMKM lebih kuat berkaitan dengan kapabilitas bisnis yang dapat diintervensi daripada variabel demografis. Usia dan gender tidak menjadi pembeda utama. Program peningkatan keberhasilan UMKM sebaiknya memperkuat praktik bisnis inti seperti pembukuan, rencana bisnis, kanal digital, dan akses konsultasi.

5. Kesimpulan dan Rekomendasi

5.1 Kesimpulan

Dataset UMKM yang dianalisis memiliki target tidak seimbang, sehingga evaluasi model harus menggunakan metrik yang memperhatikan kelas minoritas. Model machine learning dapat memprediksi keberhasilan UMKM dengan performa yang baik ketika validasi dilakukan secara stratified. Faktor yang paling penting dan actionable adalah rencana bisnis, modal awal, pencatatan keuangan, penggunaan internet, konsultasi profesional, dan pengalaman industri.

5.2 Rekomendasi

- Menyediakan template rencana bisnis sederhana yang wajib diisi dan direview oleh UMKM binaan.
- Mengadakan pelatihan pencatatan keuangan harian berbasis spreadsheet atau aplikasi kas sederhana.
- Mendorong penggunaan internet untuk katalog digital, marketplace, media sosial, dan komunikasi pelanggan.
- Menghubungkan akses modal mikro dengan kesiapan bisnis, khususnya rencana usaha dan pencatatan keuangan.
- Membuat klinik konsultasi profesional bulanan untuk aspek keuangan, pajak, pemasaran, dan operasional.
- Mengembangkan mentoring sektor usaha agar pengalaman industri dapat ditransfer ke UMKM yang lebih baru.

Daftar Pustaka

- [1] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [2] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [3] M. Kuhn and K. Johnson, *Applied Predictive Modeling*. New York, NY, USA: Springer, 2013.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009.
- [5] OECD, *SME and Entrepreneurship Outlook 2023*. Paris, France: OECD Publishing, 2023.

Lampiran

Lampiran utama terdapat pada Kaggle Notebook public yang berisi kode lengkap, output EDA, hasil validasi model, confusion matrix, ROC curve, feature importance, dan tabel rekomendasi. Pastikan link notebook sudah public sebelum dikumpulkan melalui formulir panitia.