


PREDIKSI KEBERHASILAN UMKM BERBASIS MACHINE LEARNING



Tema: Data-Driven Solution untuk Permasalahan Nyata

Nama Tim: Magic Cloud
Anggota: Evan William, Daniel, Bambang Herlambang

UNIVERSITAS WIDYA MANDALA SURABAYA

Informatics Festival 2026
Universitas PGRI Semarang

Abstrak

UMKM memiliki peran strategis dalam perekonomian, tetapi tingkat keberhasilannya dipengaruhi oleh banyak faktor operasional seperti kecukupan modal, pencatatan keuangan, penggunaan internet, rencana bisnis, pengalaman industri, dan konsultasi profesional. Makalah ini membangun pendekatan machine learning untuk memprediksi keberhasilan UMKM menggunakan dataset panitia yang terdiri atas 250 observasi dan 13 kolom. Target Success memiliki distribusi tidak seimbang, yaitu 188 UMKM tidak berhasil dan 62 UMKM berhasil. Analisis dilakukan melalui audit data, eksplorasi fitur, validasi model, interpretasi fitur, dan penyusunan rekomendasi.

Metode yang digunakan dirancang agar sesuai dengan karakteristik data kecil dan tidak seimbang: validasi stratified, baseline mayoritas, repeated cross-validation, hyperparameter tuning, evaluasi multi-metrik, dan interpretasi fitur. Dengan pendekatan ini, model tidak hanya mengejar accuracy, tetapi juga menjaga kemampuan mendeteksi kelas berhasil yang jumlahnya lebih sedikit.

Kesesuaian dengan Guideline Kompetisi

Ketentuan	Implementasi dalam Karya
Platform Kaggle Notebook	Notebook disiapkan dalam format .ipynb dan dapat langsung di-import ke Kaggle.
Bahasa Python	Seluruh proses analisis, visualisasi, modeling, dan evaluasi menggunakan Python.
Data panitia saja	Analisis hanya memakai umkm_success.csv tanpa data eksternal.
Tema data-driven solution	Hasil model diterjemahkan menjadi rekomendasi peningkatan UMKM.
Kelengkapan makalah	Makalah memuat cover, pendahuluan, teori, proses, hasil, kesimpulan, pustaka, dan lampiran.
Validitas model	Evaluasi memakai baseline, stratified split, repeated CV, tuning, dan metrik imbalance.

1. Pendahuluan

1.1 Latar Belakang

UMKM merupakan motor ekonomi lokal yang berperan dalam penciptaan lapangan kerja, pemerataan pendapatan, dan penguatan ekonomi masyarakat. Namun, tidak semua UMKM mampu bertahan dan berkembang secara berkelanjutan. Kegagalan dapat dipengaruhi oleh keterbatasan modal, rendahnya literasi pencatatan keuangan, kurangnya rencana bisnis, rendahnya pemanfaatan internet, serta minimnya akses terhadap nasihat profesional.

Pendekatan data science dapat membantu mengidentifikasi faktor yang berhubungan dengan keberhasilan UMKM. Dengan model prediktif, pendamping usaha, pemerintah, komunitas bisnis, dan pelaku UMKM dapat memprioritaskan intervensi yang paling berdampak. Analisis ini selaras dengan tema kompetisi, yaitu Data-Driven Solution untuk Permasalahan Nyata.

1.2 Rumusan Masalah

- Bagaimana karakteristik dataset UMKM yang diberikan panitia?
- Faktor apa saja yang paling berkaitan dengan keberhasilan UMKM?

- Bagaimana membangun model machine learning yang valid untuk memprediksi keberhasilan UMKM?
- Rekomendasi praktis apa yang dapat diberikan berdasarkan hasil analisis?

1.3 Tujuan

Tujuan proyek ini adalah membangun pipeline analisis dan prediksi keberhasilan UMKM, mengevaluasi model secara adil pada data yang tidak seimbang, menginterpretasikan fitur penting, dan menyusun rekomendasi nyata untuk meningkatkan peluang keberhasilan UMKM.

2. Landasan Teori

2.1 Data Science dan Machine Learning

Data science menggabungkan pengolahan data, statistik, machine learning, dan pemahaman domain untuk menghasilkan informasi yang dapat digunakan dalam pengambilan keputusan. Dalam kasus ini, machine learning digunakan untuk mempelajari pola historis antara profil UMKM dan label keberhasilan.

2.2 Klasifikasi Biner

Prediksi keberhasilan UMKM merupakan masalah klasifikasi biner karena target hanya memiliki dua kelas: berhasil dan tidak berhasil. Model yang digunakan perlu mampu membedakan kedua kelas sekaligus menjaga performa pada kelas minoritas.

2.3 Evaluasi pada Data Tidak Seimbang

Dataset memiliki distribusi target tidak seimbang: 75,2 persen kelas 0 dan 24,8 persen kelas 1. Accuracy saja tidak cukup karena model yang selalu menebak kelas mayoritas dapat terlihat cukup baik. Oleh sebab itu, evaluasi juga menggunakan balanced accuracy, precision, recall, F1-score, dan ROC-AUC.

2.4 Interpretabilitas Model

Interpretabilitas penting agar hasil prediksi dapat diterjemahkan menjadi kebijakan atau tindakan. Permutation importance digunakan untuk melihat penurunan performa ketika suatu fitur diacak. Pada model linear, koefisien terstandarisasi juga membantu membaca arah pengaruh fitur.

2.5 Risiko Overfitting dan Validasi

Jumlah data yang relatif kecil membuat model berisiko menghafal pola train set. Untuk mengurangi risiko tersebut, evaluasi tidak hanya memakai satu split, tetapi repeated stratified cross-validation. Hyperparameter tuning dilakukan pada data latih, sedangkan test set tetap dipakai sebagai simulasi data baru. Pendekatan ini menjaga agar skor model lebih representatif.

2.6 Relevansi Bisnis UMKM

Fitur seperti business plan, pencatatan keuangan, penggunaan internet, modal awal, pengalaman industri, dan konsultasi profesional merupakan faktor yang dapat ditingkatkan melalui program pendampingan. Karena itu, model prediktif dalam proyek ini diposisikan sebagai alat bantu prioritas intervensi, bukan sebagai penentu tunggal keberhasilan.

3. Proses Analisis

3.1 Data dan Variabel

Dataset `umkm_success.csv` berisi 250 baris dan 13 kolom. Variabel target adalah `Success`. Fitur yang dianalisis meliputi usia pemilik, pendidikan, kecukupan modal awal, pencatatan keuangan, penggunaan internet, rencana bisnis, usaha pemasaran, kemitraan, pengalaman bisnis orang tua, pengalaman industri, gender pemilik, dan frekuensi konsultasi profesional.

3.2 Audit Kualitas Data

Audit awal menunjukkan tidak terdapat missing value pada seluruh kolom. Semua variabel terbaca sebagai numerik. Target terdiri atas 188 data tidak berhasil dan 62 data berhasil. Ketidakseimbangan ini menjadi pertimbangan utama dalam pemilihan metrik dan strategi validasi.

3.3 EDA, Modeling, dan Validasi

EDA dilakukan dengan melihat distribusi target, ringkasan statistik, success rate pada fitur biner, boxplot fitur numerik terhadap target, dan korelasi antarvariabel. Notebook membandingkan baseline mayoritas dengan Logistic Regression, Random Forest, Extra Trees, Gradient Boosting, dan AdaBoost. Data dipisahkan secara stratified, cross-validation menggunakan `RepeatedStratifiedKFold`, dan model terbaik dipilih berdasarkan ROC-AUC serta F1-score.

3.4 Desain Eksperimen

Komponen	Keputusan Metodologis
Target	Success sebagai klasifikasi biner 0/1.
Split data	Train-test split 80:20 dengan stratifikasi kelas.
Cross-validation	<code>RepeatedStratifiedKFold</code> 5 fold dan 3 repeat pada train set.
Baseline	<code>DummyClassifier</code> mayoritas sebagai pembanding minimum.
Model kandidat	Logistic Regression, Random Forest, Extra Trees, Gradient Boosting, AdaBoost.
Tuning	<code>GridSearchCV</code> dengan scoring ROC-AUC pada kandidat model kuat.
Threshold	Threshold alternatif dipilih dari train set berdasarkan F1 dan balanced accuracy.

3.5 Alasan Pemilihan Metrik

Accuracy tetap dilaporkan karena mudah dipahami, tetapi bukan satu-satunya indikator. Balanced accuracy dipakai agar kelas berhasil dan tidak berhasil mendapat bobot seimbang. Precision menunjukkan ketepatan prediksi berhasil, recall menunjukkan kemampuan menemukan UMKM yang benar-benar berhasil, F1-score menyeimbangkan precision dan recall, sedangkan ROC-AUC mengukur kualitas ranking probabilitas model.

3.6 Alur Kerja Teknis dari Awal hingga Akhir

Tahap	Proses	Tujuan
1. Load data	Membaca <code>umkm_success.csv</code> dari input Kaggle	Memastikan data hanya memakai data panitia.
2. Validasi schema	Mengecek urutan kolom, tipe numerik, target biner, dan tidak ada duplikasi	Memastikan data siap dianalisis.

Tahap	Proses	Tujuan
3. Pemisahan fitur-target	Fitur X berisi 12 variabel prediktor; target y hanya kolom Success	Mencegah success leakage.
4. EDA	Distribusi target, success rate fitur biner, boxplot	Memeriksa data berhasil dan faktor bisnis yang relevan.
5. Split data	Train-test split 80:20 dengan stratifikasi target.	Menjaga proporsi kelas berhasil/tidak berhasil pada train dan test.
6. Modeling	Baseline, Logistic Regression, Random Forest, Ensemble, Gradient Boosting, AdaBoost, dan non-linear.	Membandingkan model.
7. Validasi	Repeated stratified cross-validation dan GridSearch	Mengurangi bias dari satu pembagian data saja.
8. Evaluasi akhir	Accuracy, balanced accuracy, precision, recall, F1 score, ROC-AUC, confusion matrix	Memeriksa apakah model pada data tidak seimbang.
9. Interpretasi	Permutation importance dan koefisien Logistic Regression	Mengidentifikasi faktor yang paling memengaruhi prediksi.
10. Rekomendasi	Menerjemahkan fitur penting menjadi program pemasaran	Menghasilkan solusi nyata berbasis data.

3.7 Rincian Train-Test Split

Karena dataset hanya berisi 250 baris, jumlah data latih dan data uji memang relatif kecil. Hal ini bukan kekurangan proses analisis, melainkan keterbatasan dari dataset resmi yang diberikan panitia. Untuk menjaga evaluasi tetap adil, pembagian data dilakukan secara stratified sehingga proporsi kelas berhasil tetap mirip antara data latih dan data uji.

Subset	Jumlah Data	Tidak Berhasil (0)	Berhasil (1)	Persentase Berhasil
Train	200	150	50	25,0%
Test	50	38	12	24,0%
Total	250	188	62	24,8%

3.8 Pencegahan Data Leakage

Validitas model diperkuat dengan beberapa pemeriksaan. Kolom Success tidak dimasukkan ke matriks fitur. Proses scaling dilakukan di dalam Pipeline sehingga scaler hanya belajar dari data latih pada setiap fold. Tidak ditemukan duplikasi baris, tidak ditemukan duplikasi kombinasi fitur, dan tidak ditemukan overlap fitur persis antara train dan test. Selain itu, uji sanity dengan label yang diacak menunjukkan ROC-AUC turun ke sekitar 0,49 atau mendekati random, sehingga performa tinggi pada label asli tidak disebabkan oleh kebocoran target.

4. Hasil Analisis

4.1 Ringkasan Dataset

Indikator	Nilai
Jumlah baris	250
Jumlah kolom	13
Jumlah fitur prediktor	12
Missing value	0
Kelas tidak berhasil	188 (75,2%)
Kelas berhasil	62 (24,8%)

4.2 Pola Success Rate

Fitur	Kondisi 0	Kondisi 1	Interpretasi
Business_Plan	8,4%	39,7%	Rencana bisnis sangat terkait dengan peluang berhasil.
Initial_Capital	9,9%	38,8%	Modal awal memadai membantu stabilitas operasional.
Financial_Record_Keeping	10,9%	39,3%	Pencatatan baik membantu kontrol arus kas dan evaluasi.
Internet_Usage	12,1%	40,9%	Internet mendukung pemasaran dan pasar digital.
Owner_Gender	24,8%	24,8%	Gender bukan pembeda utama pada dataset ini.

4.3 Hasil Model

Model terbaik pada eksperimen adalah Logistic Regression dengan StandardScaler dan class_weight='balanced'. Pemilihan ini tepat untuk dataset kecil karena model linear cenderung stabil, mudah dijelaskan, dan tidak terlalu mudah overfit dibanding model yang sangat kompleks. Model ini juga tetap dibandingkan dengan Random Forest, Extra Trees, Gradient Boosting, dan AdaBoost agar pemilihan model tidak hanya berdasarkan asumsi.

Baseline mayoritas pada dataset ini adalah 75,2 persen karena kelas tidak berhasil berjumlah 188 dari 250 data. Model yang baik harus melampaui baseline tersebut dan tetap mampu mengenali kelas berhasil yang lebih sedikit. Hasil test set menunjukkan accuracy 90,0 persen, balanced accuracy 93,4 persen, F1-score kelas berhasil 82,8 persen, dan ROC-AUC 98,9 persen. Dengan demikian, nilai 98,9 persen bukan accuracy, melainkan ROC-AUC yang mengukur kualitas pemeringkatan probabilitas.

4.3.1 Ringkasan Cross-Validation Model Terbaik

Metrik Cross-Validation	Nilai Rata-Rata	Makna
Accuracy	95,7%	Proporsi prediksi benar pada validasi silang.
Balanced Accuracy	96,1%	Kinerja rata-rata seimbang pada kelas 0 dan 1.
Precision	88,1%	Ketepatan prediksi kelas berhasil.
Recall	96,8%	Kemampuan menemukan UMKM yang berhasil.
F1-score	92,0%	Keseimbangan precision dan recall.
ROC-AUC	99,2%	Kemampuan ranking probabilitas antara kelas berhasil dan tidak berhasil.

4.3.2 Hasil Evaluasi pada Test Set

Metrik Test Set	Nilai	Interpretasi
Accuracy	90,0%	45 dari 50 data test diprediksi benar.
Balanced Accuracy	93,4%	Model tidak hanya kuat pada kelas mayoritas.
Precision kelas 1	70,6%	Sebagian prediksi berhasil masih false positive, tetapi tetap cukup baik.
Recall kelas 1	100,0%	Seluruh UMKM berhasil pada test set berhasil terdeteksi.
F1-score kelas 1	82,8%	Kinerja kelas berhasil tetap kuat meskipun data tidak seimbang.
ROC-AUC	98,9%	Model sangat baik dalam membedakan ranking probabilitas kedua kelas.

4.3.3 Confusion Matrix

Aktual / Prediksi	Prediksi Tidak Berhasil (0)	Prediksi Berhasil (1)	Interpretasi
Aktual Tidak Berhasil (0)	33	5	Sebagian kecil UMKM tidak berhasil diprediksi berhasil
Aktual Berhasil (1)	0	12	Semua UMKM berhasil pada test set berhasil terdeteksi

Confusion matrix menunjukkan bahwa model tidak sekadar menebak kelas mayoritas. Jika model hanya menebak semua data sebagai tidak berhasil, maka recall untuk kelas berhasil akan menjadi 0 persen. Pada hasil ini, recall kelas berhasil justru 100 persen, sehingga model benar-benar menangkap pola yang membedakan UMKM berhasil dari tidak berhasil.

4.3.4 Perbandingan dengan Baseline

Model	Accuracy	Balanced Accuracy	F1 Kelas Berhasil	ROC-AUC
Baseline mayoritas	75,2%	50,0%	0,0%	50,0%
Logistic Regression final	90,0%	93,4%	82,8%	98,9%

Perbandingan baseline memperjelas bahwa model tidak hanya memanfaatkan ketidakseimbangan kelas. Peningkatan paling penting terlihat pada balanced accuracy, F1-score kelas berhasil, dan ROC-AUC.

Metrik	Fungsi	Interpretasi yang Diharapkan
Accuracy	Mengukur proporsi prediksi benar.	Harus lebih baik dari baseline mayoritas 75,2%.
Balanced Accuracy	Menyeimbangkan performa kelas 0 dan 1.	Penting karena target tidak seimbang.
Precision	Ketepatan prediksi kelas berhasil.	Mengurangi false positive pada rekomendasi intervensi.
Recall	Kemampuan menemukan kelas berhasil.	Mengurangi kasus berhasil yang tidak terdeteksi.
F1-score	Rata-rata harmonik precision dan recall.	Metrik utama praktis untuk target tidak seimbang.
ROC-AUC	Kualitas pemeringkatan probabilitas.	Stabil untuk membandingkan model lintas threshold.

4.4 Interpretasi Fitur

Fitur dengan kontribusi paling kuat secara konsisten adalah Internet_Usage, Business_Plan, Financial_Record_Keeping, Initial_Capital, Professional_Advice, dan Industry_Experience. Temuan ini penting karena sebagian besar faktor tersebut dapat ditingkatkan melalui pelatihan, pendampingan, akses modal, dan transformasi digital.

4.5 Diskusi

Hasil analisis menunjukkan bahwa keberhasilan UMKM lebih kuat berkaitan dengan kapabilitas bisnis yang dapat diintervensi daripada variabel demografis. Usia dan gender tidak menjadi pembeda utama. Program peningkatan keberhasilan UMKM sebaiknya memperkuat praktik bisnis inti seperti pembukuan, rencana bisnis, kanal digital, dan akses konsultasi.

4.6 Implikasi Data-Driven Solution

Faktor	Masalah Nyata	Solusi Berbasis Data
Business_Plan	Banyak usaha berjalan tanpa arah dan target yang jelas.	Menyediakan template rencana bisnis ringkas untuk UMKM binaan.

Faktor	Masalah Nyata	Solusi Berbasis Data
Financial_Record_Keeping	Pelaku usaha sulit membaca arus kas dan laporan keuangan.	Pelatihan pembukuan mingguan dan dashboard kas sederhana.
Internet_Usage	Akses pasar terbatas pada pelanggan sekitar.	Onboarding marketplace, katalog digital, dan konten media sosial.
Initial_Capital	Keterbatasan modal menghambat stok dan operasional.	Skema modal mikro berbasis kesiapan rencana dan pembukuan.
Professional_Advice	Keputusan usaha sering tidak tervalidasi.	Klinik konsultasi bisnis berkala dengan mentor keuangan dan pemasaran.

4.7 Keterbatasan Analisis

Dataset hanya berisi 250 observasi sehingga performa model harus dibaca secara hati-hati. Label keberhasilan juga bergantung pada definisi panitia dan tidak memuat dimensi waktu. Beberapa faktor eksternal seperti lokasi, sektor usaha rinci, kondisi pasar, dan omzet historis tidak tersedia. Karena itu, model sebaiknya digunakan sebagai alat bantu analisis awal, bukan keputusan final tanpa verifikasi lapangan.

5. Kesimpulan dan Rekomendasi

5.1 Kesimpulan

Dataset UMKM yang dianalisis memiliki target tidak seimbang, sehingga evaluasi model harus menggunakan metrik yang memperhatikan kelas minoritas. Model machine learning dapat memprediksi keberhasilan UMKM dengan performa yang baik ketika validasi dilakukan secara stratified. Faktor yang paling penting dan actionable adalah rencana bisnis, modal awal, pencatatan keuangan, penggunaan internet, konsultasi profesional, dan pengalaman industri.

5.2 Rekomendasi

- Menyediakan template rencana bisnis sederhana yang wajib diisi dan direview oleh UMKM binaan.
- Mengadakan pelatihan pencatatan keuangan harian berbasis spreadsheet atau aplikasi kas sederhana.
- Mendorong penggunaan internet untuk katalog digital, marketplace, media sosial, dan komunikasi pelanggan.
- Menghubungkan akses modal mikro dengan kesiapan bisnis, khususnya rencana usaha dan pencatatan keuangan.
- Membuat klinik konsultasi profesional bulanan untuk aspek keuangan, pajak, pemasaran, dan operasional.
- Mengembangkan mentoring sektor usaha agar pengalaman industri dapat ditransfer ke UMKM yang lebih baru.

5.3 Rencana Tindak Lanjut

Tindak lanjut yang disarankan adalah membangun dashboard sederhana untuk memantau skor risiko UMKM, menambahkan data longitudinal seperti omzet bulanan dan umur usaha, serta melakukan validasi lapangan terhadap rekomendasi model. Jika data baru tersedia, model dapat diperbarui secara berkala agar tetap relevan dengan perubahan pasar.

Daftar Pustaka

- [1] L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [2] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [3] M. Kuhn and K. Johnson, Applied Predictive Modeling. New York, NY, USA: Springer, 2013.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning, 2nd ed. New York, NY, USA: Springer, 2009.
- [5] OECD, SME and Entrepreneurship Outlook 2023. Paris, France: OECD Publishing, 2023.

Lampiran

Lampiran utama terdapat pada Kaggle Notebook public yang berisi kode lengkap, output EDA, hasil validasi model, confusion matrix, ROC curve, feature importance, dan tabel rekomendasi. Pastikan link notebook sudah public sebelum dikumpulkan melalui formulir panitia.