


PREDIKSI KEBERHASILAN UMKM BERBASIS MACHINE LEARNING



Tema: Data-Driven Solution untuk Permasalahan Nyata

Nama Tim: Magic Cloud

Anggota: Evan William, Daniel, Bambang Herlambang

UNIVERSITAS WIDYA MANDALA SURABAYA

Informatics Festival 2026
Universitas PGRI Semarang

Abstrak

UMKM memiliki peran strategis dalam perekonomian, tetapi tingkat keberhasilannya dipengaruhi oleh banyak faktor operasional seperti kecukupan modal, pencatatan keuangan, penggunaan internet, rencana bisnis, pengalaman industri, dan konsultasi profesional. Makalah ini membangun pendekatan machine learning untuk memprediksi keberhasilan UMKM menggunakan dataset panitia yang terdiri atas 250 observasi dan 13 kolom. Target Success memiliki distribusi tidak seimbang, yaitu 188 UMKM tidak berhasil dan 62 UMKM berhasil. Analisis dilakukan melalui audit data, eksplorasi fitur, validasi model, interpretasi fitur, dan penyusunan rekomendasi.

Metode yang digunakan dirancang agar sesuai dengan karakteristik data kecil dan tidak seimbang: validasi stratified, baseline mayoritas, repeated cross-validation, hyperparameter tuning, evaluasi multi-metrik, dan interpretasi fitur. Dengan pendekatan ini, model tidak hanya mengejar accuracy, tetapi juga menjaga kemampuan mendeteksi kelas berhasil yang jumlahnya lebih sedikit.

Kesesuaian dengan Guideline Kompetisi

Ketentuan	Implementasi dalam Karya
Platform Kaggle Notebook	Notebook disiapkan dalam format .ipynb dan dapat langsung di-import ke Kaggle.
Bahasa Python	Seluruh proses analisis, visualisasi, modeling, dan evaluasi menggunakan Python.
Data panitia saja	Analisis hanya memakai umkm_success.csv tanpa data eksternal.
Tema data-driven solution	Hasil model diterjemahkan menjadi rekomendasi peningkatan UMKM.
Kelengkapan makalah	Makalah memuat cover, pendahuluan, teori, proses, hasil, kesimpulan, pustaka, dan lampiran.
Validitas model	Evaluasi memakai baseline, stratified split, repeated CV, tuning, dan metrik imbalance.

1. Pendahuluan

1.1 Latar Belakang

UMKM merupakan motor ekonomi lokal yang berperan dalam penciptaan lapangan kerja, pemerataan pendapatan, dan penguatan ekonomi masyarakat. Namun, tidak semua UMKM mampu bertahan dan berkembang secara berkelanjutan. Kegagalan dapat dipengaruhi oleh keterbatasan modal, rendahnya literasi pencatatan keuangan, kurangnya rencana bisnis, rendahnya pemanfaatan internet, serta minimnya akses terhadap nasihat profesional.

Pendekatan data science dapat membantu mengidentifikasi faktor yang berhubungan dengan keberhasilan UMKM. Dengan model prediktif, pendamping usaha, pemerintah, komunitas bisnis, dan pelaku UMKM dapat memprioritaskan intervensi yang paling berdampak. Analisis ini selaras dengan tema kompetisi, yaitu Data-Driven Solution untuk Permasalahan Nyata.

1.2 Rumusan Masalah

- Bagaimana karakteristik dataset UMKM yang diberikan panitia?
- Faktor apa saja yang paling berkaitan dengan keberhasilan UMKM?

- Bagaimana membangun model machine learning yang valid untuk memprediksi keberhasilan UMKM?
- Rekomendasi praktis apa yang dapat diberikan berdasarkan hasil analisis?

1.3 Tujuan

Tujuan proyek ini adalah membangun pipeline analisis dan prediksi keberhasilan UMKM, mengevaluasi model secara adil pada data yang tidak seimbang, menginterpretasikan fitur penting, dan menyusun rekomendasi nyata untuk meningkatkan peluang keberhasilan UMKM.

2. Landasan Teori

2.1 Data Science dan Machine Learning

Data science menggabungkan pengolahan data, statistik, machine learning, dan pemahaman domain untuk menghasilkan informasi yang dapat digunakan dalam pengambilan keputusan. Dalam kasus ini, machine learning digunakan untuk mempelajari pola historis antara profil UMKM dan label keberhasilan.

2.2 Klasifikasi Biner

Prediksi keberhasilan UMKM merupakan masalah klasifikasi biner karena target hanya memiliki dua kelas: berhasil dan tidak berhasil. Model yang digunakan perlu mampu membedakan kedua kelas sekaligus menjaga performa pada kelas minoritas.

2.3 Evaluasi pada Data Tidak Seimbang

Dataset memiliki distribusi target tidak seimbang: 75,2 persen kelas 0 dan 24,8 persen kelas 1. Accuracy saja tidak cukup karena model yang selalu menebak kelas mayoritas dapat terlihat cukup baik. Oleh sebab itu, evaluasi juga menggunakan balanced accuracy, precision, recall, F1-score, dan ROC-AUC.

2.4 Interpretabilitas Model

Interpretabilitas penting agar hasil prediksi dapat diterjemahkan menjadi kebijakan atau tindakan. Permutation importance digunakan untuk melihat penurunan performa ketika suatu fitur diacak. Pada model linear, koefisien terstandarisasi juga membantu membaca arah pengaruh fitur.

2.5 Risiko Overfitting dan Validasi

Jumlah data yang relatif kecil membuat model berisiko menghafal pola train set. Untuk mengurangi risiko tersebut, evaluasi tidak hanya memakai satu split, tetapi repeated stratified cross-validation. Hyperparameter tuning dilakukan pada data latih, sedangkan test set tetap dipakai sebagai simulasi data baru. Pendekatan ini menjaga agar skor model lebih representatif.

2.6 Relevansi Bisnis UMKM

Fitur seperti business plan, pencatatan keuangan, penggunaan internet, modal awal, pengalaman industri, dan konsultasi profesional merupakan faktor yang dapat ditingkatkan melalui program pendampingan. Karena itu, model prediktif dalam proyek ini diposisikan sebagai alat bantu prioritas intervensi, bukan sebagai penentu tunggal keberhasilan.

3. Proses Analisis

3.1 Data dan Variabel

Dataset `umkm_success.csv` berisi 250 baris dan 13 kolom. Variabel target adalah Success. Fitur yang dianalisis meliputi usia pemilik, pendidikan, kecukupan modal awal, pencatatan keuangan, penggunaan internet, rencana bisnis, usaha pemasaran, kemitraan, pengalaman bisnis orang tua, pengalaman industri, gender pemilik, dan frekuensi konsultasi profesional.

3.2 Audit Kualitas Data

Audit awal menunjukkan tidak terdapat missing value pada seluruh kolom. Semua variabel terbaca sebagai numerik. Target terdiri atas 188 data tidak berhasil dan 62 data berhasil. Ketidakseimbangan ini menjadi pertimbangan utama dalam pemilihan metrik dan strategi validasi.

3.3 EDA, Modeling, dan Validasi

EDA dilakukan dengan melihat distribusi target, ringkasan statistik, success rate pada fitur biner, boxplot fitur numerik terhadap target, dan korelasi antarvariabel. Notebook membandingkan baseline mayoritas dengan Logistic Regression, Random Forest, Extra Trees, Gradient Boosting, dan AdaBoost. Data dipisahkan secara stratified, cross-validation menggunakan RepeatedStratifiedKFold, dan model terbaik dipilih berdasarkan ROC-AUC serta F1-score.

3.4 Desain Eksperimen

Komponen	Keputusan Metodologis
Target	Success sebagai klasifikasi biner 0/1.
Split data	Train-test split 80:20 dengan stratifikasi kelas.
Cross-validation	RepeatedStratifiedKFold 5 fold dan 10 repeat pada train set.
Baseline	DummyClassifier mayoritas sebagai pembanding minimum.
Model kandidat	Logistic Regression, Random Forest, Extra Trees, Gradient Boosting, AdaBoost.
Tuning	GridSearchCV dengan scoring ROC-AUC pada kandidat model kuat.
Threshold	Threshold alternatif dipilih dari train set berdasarkan F1 dan balanced accuracy.

3.5 Alasan Pemilihan Metrik

Accuracy tetap dilaporkan karena mudah dipahami, tetapi bukan satu-satunya indikator. Balanced accuracy dipakai agar kelas berhasil dan tidak berhasil mendapat bobot seimbang. Precision menunjukkan ketepatan prediksi berhasil, recall menunjukkan kemampuan menemukan UMKM yang benar-benar berhasil, F1-score menyeimbangkan precision dan recall, sedangkan ROC-AUC mengukur kualitas ranking probabilitas model.

4. Hasil Analisis

4.1 Ringkasan Dataset

Indikator	Nilai
Jumlah baris	250
Jumlah kolom	13
Jumlah fitur prediktor	12
Missing value	0
Kelas tidak berhasil	188 (75,2%)
Kelas berhasil	62 (24,8%)

4.2 Pola Success Rate

Fitur	Kondisi 0	Kondisi 1	Interpretasi
Business_Plan	8,4%	39,7%	Rencana bisnis sangat terkait dengan peluang berhasil.
Initial_Capital	9,9%	38,8%	Modal awal memadai membantu stabilitas operasional.
Financial_Record_Keeping	10,9%	39,3%	Pencatatan baik membantu kontrol arus kas dan evaluasi.
Internet_Usage	12,1%	40,9%	Internet mendukung pemasaran dan pasar digital.
Owner_Gender	24,8%	24,8%	Gender bukan pembeda utama pada dataset ini.

4.3 Hasil Model

Pada validasi lokal berbasis Logistic Regression terstandarisasi dengan class balancing, hasil indikatif yang diperoleh adalah accuracy sekitar 0,939, balanced accuracy sekitar 0,952, F1-score sekitar 0,890, dan ROC-AUC sekitar 0,989 pada repeated stratified cross-validation. Pada holdout stratified, threshold yang disesuaikan memberi accuracy sekitar 0,941, F1-score sekitar 0,889, dan ROC-AUC sekitar 0,994. Nilai final pada Kaggle dapat sedikit berbeda karena notebook melakukan pemilihan model dan tuning ulang secara langsung.

Metrik	Fungsi	Interpretasi yang Diharapkan
Accuracy	Mengukur proporsi prediksi benar.	Harus lebih baik dari baseline mayoritas 75,2%.
Balanced Accuracy	Menyeimbangkan performa kelas 0 dan 1.	Penting karena target tidak seimbang.
Precision	Ketepatan prediksi kelas berhasil.	Mengurangi false positive pada rekomendasi intervensi.
Recall	Kemampuan menemukan kelas berhasil.	Mengurangi kasus berhasil yang tidak terdeteksi.
F1-score	Rata-rata harmonik precision dan recall.	Metrik utama praktis untuk target tidak seimbang.
ROC-AUC	Kualitas pemeringkatan probabilitas.	Stabil untuk membandingkan model lintas threshold.

4.4 Interpretasi Fitur

Fitur dengan kontribusi paling kuat secara konsisten adalah Internet_Usage, Business_Plan, Financial_Record_Keeping, Initial_Capital, Professional_Advice, dan Industry_Experience. Temuan ini penting karena sebagian besar faktor tersebut dapat ditingkatkan melalui pelatihan, pendampingan, akses modal, dan transformasi digital.

4.5 Diskusi

Hasil analisis menunjukkan bahwa keberhasilan UMKM lebih kuat berkaitan dengan kapabilitas bisnis yang dapat diintervensi daripada variabel demografis. Usia dan gender tidak menjadi pembeda utama. Program peningkatan keberhasilan UMKM sebaiknya memperkuat praktik bisnis inti seperti pembukuan, rencana bisnis, kanal digital, dan akses konsultasi.

4.6 Implikasi Data-Driven Solution

Faktor	Masalah Nyata	Solusi Berbasis Data
Business_Plan	Banyak usaha berjalan tanpa arah dan target yang jelas.	Wajibkan template rencana bisnis ringkas untuk UMKM binaan.
Financial_Record_Keeping	Pelaku usaha sulit membaca arus kas dan laba rugi.	Latihan pembukuan mingguan dan dashboard kas sederhana.
Internet_Usage	Akses pasar terbatas pada pelanggan sekitar lokasi.	Onboarding marketplace, katalog digital, dan konten media sosial.
Initial_Capital	Keterbatasan modal menghambat stok dan operasional.	Siperasional mikro berbasis kesiapan rencana dan pembukuan.
Professional_Advice	Keputusan usaha sering tidak tervalidasi.	Klinik konsultasi bisnis berkala dengan mentor keuangan dan pemasaran.

4.7 Keterbatasan Analisis

Dataset hanya berisi 250 observasi sehingga performa model harus dibaca secara hati-hati. Label keberhasilan juga bergantung pada definisi panitia dan tidak memuat dimensi waktu. Beberapa faktor eksternal seperti lokasi, sektor usaha rinci, kondisi pasar, dan omzet historis tidak tersedia. Karena itu, model sebaiknya digunakan sebagai alat bantu analisis awal, bukan keputusan final tanpa verifikasi lapangan.

5. Kesimpulan dan Rekomendasi

5.1 Kesimpulan

Dataset UMKM yang dianalisis memiliki target tidak seimbang, sehingga evaluasi model harus menggunakan metrik yang memperhatikan kelas minoritas. Model machine learning dapat memprediksi keberhasilan UMKM dengan performa yang baik ketika validasi dilakukan secara stratified. Faktor yang paling penting dan actionable adalah rencana bisnis, modal awal, pencatatan keuangan, penggunaan internet, konsultasi profesional, dan pengalaman industri.

5.2 Rekomendasi

- Menyediakan template rencana bisnis sederhana yang wajib diisi dan direview oleh UMKM binaan.
- Mengadakan pelatihan pencatatan keuangan harian berbasis spreadsheet atau aplikasi kas sederhana.
- Mendorong penggunaan internet untuk katalog digital, marketplace, media sosial, dan komunikasi pelanggan.
- Menghubungkan akses modal mikro dengan kesiapan bisnis, khususnya rencana usaha dan pencatatan keuangan.
- Membuat klinik konsultasi profesional bulanan untuk aspek keuangan, pajak, pemasaran, dan operasional.
- Mengembangkan mentoring sektor usaha agar pengalaman industri dapat ditransfer ke UMKM yang lebih baru.

5.3 Rencana Tindak Lanjut

Tindak lanjut yang disarankan adalah membangun dashboard sederhana untuk memantau skor risiko UMKM, menambahkan data longitudinal seperti omzet bulanan dan umur usaha, serta melakukan validasi lapangan terhadap rekomendasi model. Jika data baru tersedia, model dapat diperbarui secara berkala agar tetap relevan dengan perubahan pasar.

Daftar Pustaka

- [1] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [2] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [3] M. Kuhn and K. Johnson, *Applied Predictive Modeling*. New York, NY, USA: Springer, 2013.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009.
- [5] OECD, *SME and Entrepreneurship Outlook 2023*. Paris, France: OECD Publishing, 2023.

Lampiran

Lampiran utama terdapat pada Kaggle Notebook public yang berisi kode lengkap, output EDA, hasil validasi model, confusion matrix, ROC curve, feature importance, dan tabel rekomendasi. Pastikan link notebook sudah public sebelum dikumpulkan melalui formulir panitia.